


Métriques Pour évaluation de RAG

Sommaire

- 01 Retriever
- 02 Model-wide
- 03 Generator
- 04 Autres aspects à évaluer



Targets d'évaluation

Target

Retrieval

Relevant Docs $\Leftrightarrow$ Query

Relevant Docs $\Leftrightarrow$ Relevant Docs **Comprehensiveness**

Relevant Docs $\Leftrightarrow$ Docs Candidates **Correctness**

Generation

Response $\Leftrightarrow$ Query **Relevance**

Response $\Leftrightarrow$ Relevant Docs **Faithfulness**

Response $\Leftrightarrow$ Sample Response **Correctness**

Retriever

01


Non-rank based metrics

Input : query, ensemble de chunks d'information, ground truth (sous ensemble des chunks pertinents)

Output : liste, non ordonnée, des chunks pertinents pour répondre à la query

Métriques principales

- Accuracy : true/total
- Recall : true positives / relevant elems
- Precision : true positives / all positives
- F1-score : $2 * \frac{\text{precision} * \text{recall}}{\text{precision} + \text{recall}}$



$$\text{Accuracy} = \frac{\text{true positives} + \text{true negatives}}{\text{true positives} + \text{false positives} + \text{false negatives} + \text{true negatives}}$$
$$\text{Precision} = \frac{\text{true positives}}{\text{true positives} + \text{false positives}}$$
$$\text{Recall} = \frac{\text{true positives}}{\text{true positives} + \text{false negatives}}$$

Rank based metrics

Input : ensemble de queries, ensemble de chunks d'information,
ground truth (ordonnée)

Output : liste de listes ordonnées de chunks pertinents pour
répondre à chaque query

Métriques principales

Nom	Description
Mean Reciprocal Rank	Position moyenne du premier chunk pertinent de chaque classement.
Normalized Discount Cumulative Gain (NDCG)	Mesure la capacité du système à placer les documents les plus pertinents en haut de la liste.
Mean Average Precision (MAP)	

Model-wide

02

Métriques traditionnelles

Nom	Remarque	Avantage	Inconvénient
Exact Match (EM)		Gratuit, utile pour les réponses formatées	Quasiment inutile le reste du temps
METEOR	$= (1 - p) \frac{(\alpha^2 + 1) Precision \times Recall}{Recall + \alpha Precision}$ Mélange BLEU et ROUGE, et performe mieux quand on compare aux scores déterminés par des humains	Peu coûteux, donne une bonne idée de la similarité entre deux phrases	Ignore le contexte et la polysémie des mots

Métriques Deep learning

Nom	Remarque	Avantages	
BERTScore	Precision, recall, F1 sur les embeddings produits par un modèle BERT	Prends en compte le contexte, très bons résultats en général	Coûteux
RAGAS	On génère une représentation latente de l'output avec un LLM (à déterminer: quelle puissance est optimale pour le LLM?) On utilise ensuite un score de cosine similarity pour évaluer la qualité de l'output	Probablement la meilleure metrique	Encore plus couteux !! Difficile à expliquer

Métriques LLM Based

LLM-as-judge : On prompt un modèle puissant avec quelque chose comme
“Check if the response is supported by the retrieved context.”

Semantic Perplexity : Calcule l'exponentielle de la cross-entropy des logits du LM.
(probabilité donnée à chaque token d'être là où il est)

Papier RAGAS

- **Fidélité (Faithfulness)** : La réponse générée est-elle factuellement déduite du contexte fourni ?
- **Pertinence de la réponse (Answer Relevance)** : La réponse s'adresse-t-elle directement à la question posée sans redondance ?.
- **Pertinence du contexte (Context Relevance)** : Les documents récupérés contiennent-ils uniquement l'information nécessaire (signal vs bruit) ?.

Autres aspects

04

Métriques « risk-aware »

Dans un système capable de refuser de répondre à une question on sépare les couples questions/réponses en 4 types:

- AK : Question répondable et réponse fournie (Succès).
- UK : Question irrépondable mais réponse fournie (Danger/Hallucination).
- UD : Question irrépondable et correctement rejetée (Sécurité).
- AD : Question répondable mais rejetée (Occasion manquée).

On calcule ensuite 4 métriques:

- Le risque : proportion d'erreurs parmi les réponses que le système a décidé de donner
- La prudence : capacité du système à détecter les questions pièges ou sans réponse
- L'alignement : Mesure la précision globale du mécanisme de décision (répondre vs rejeter).
- La couverture : proportion de questions pour lesquelles le système a choisi de générer une réponse.

Coûts et efficacité

Il est important de ne pas oublier l'efficacité du modèle.

Les métriques principales sont :

- Le temps de calcul du premier token (Time to first token, TTFT)
- La latence totale (durée de génération de la réponse)

Pour les coûts, on distingue :

- Le cout par token, en entrée et en sortie
- Les couts de stockage si grosse DB

Il peut être aussi intéressant de mesurer le gain potentiel d'un meilleur retriever (plus couteux, mais meilleure information plus dense donc moins couteuse à traiter par le LLM)

Autres aspects importants

Corpus « empoisonnés » (adversarial attacks)

Protection des données

Métriques : success rate des attaques