

Avancement de la Recherche Bibliographique : Typologie et Stratégies de Génération pour RAG

Analyse du papier : "Know Your RAG: Dataset Taxonomy and Generation Strategies"

Projet RAG - Phase 1

20 novembre 2025

Plan de la présentation

- ➊ Contexte et Objectifs
- ➋ Problèmes Identifiés
- ➌ Contribution 1 : Taxonomie des Questions
- ➍ Contribution 2 : Stratégies de Génération
- ➎ Conclusion et Inférences
- ➏ Synthèse Phase 1 : Feuille de Route Méthodologique

Contexte : L'essor du RAG industriel

L'adoption industrielle

L'adoption rapide des systèmes RAG (Retrieval-Augmented Generation) dans l'industrie répond à un besoin critique : permettre aux LLM d'exploiter des données d'entreprise privées pour générer des réponses ancrées, réduisant ainsi significativement les hallucinations.

Le défi de l'évaluation

Pendant, une problématique majeure émerge lors de la validation de ces systèmes. Les jeux de données d'évaluation standards ou générés synthétiquement souffrent souvent d'un manque de représentativité par rapport à la complexité des cas d'usage réels, ce qui peut mener à la conception de systèmes sous-optimaux.

Les deux problèmes majeurs des données d'évaluation

L'étude met en lumière deux obstacles fondamentaux qui faussent l'évaluation des performances :

1. Le déséquilibre des données publiques

Les benchmarks publics largement utilisés présentent souvent une distribution inégale en termes de complexité. Ils ne testent pas uniformément toutes les capacités requises (recherche simple, synthèse, raisonnement), biaisant ainsi les scores globaux.

2. L'homogénéité synthétique

Les outils courants de génération de données par LLM (méthodes "Vanilla") produisent des questions massivement uniformes. Par exemple, une stratégie de prompting simple génère jusqu'à **95 % de questions de type `fact_single`**, négligeant les interactions complexes.

Une nouvelle taxonomie pour qualifier la difficulté

Pour pallier ces biais, une classification basée sur la **nature de la réponse par rapport au contexte** est proposée. Elle permet d'identifier différents niveaux de difficulté pour l'étape de *retrieval*.

Classe	Description et Nature de la Réponse
Fact Single	La réponse est explicite dans le contexte et contient une seule unité d'information. C'est une réponse factuelle directe.
Summary	La réponse est explicite mais dispersée. Elle nécessite la condensation de plusieurs unités d'information, exigeant une capacité de synthèse.
Reasoning	La réponse n'est pas explicitement mentionnée . Elle doit être inférée du contexte via un raisonnement logique simple (abstractions).
Unanswerable	La réponse n'est ni présente ni inférable. Cette classe teste la capacité du système à s'abstenir en cas de contexte non pertinent.

Impact du type de question sur le Retrieval

Variabilité de la performance (Recall@5)

L'analyse démontre que la performance du module de recherche dépend fortement du type de question. Les questions `fact_single` obtiennent généralement les scores les plus élevés car les mots-clés sont présents dans le texte. À l'inverse, les questions de `reasoning`, qui nécessitent des abstractions, affichent les scores de rappel les plus faibles.

Conséquence pour l'optimisation

Il n'existe pas de "stratégie unique" pour la recherche hybride (poids vectoriel vs lexical). L'optimum varie non seulement selon le jeu de données, mais aussi selon les étiquettes au sein d'un même jeu. Une évaluation granulaire est donc indispensable.

Stratégie 1 : L'Extraction d'Affirmations (Statement Extraction)

Pour contrer la tendance des LLM à générer des questions simplistes, l'étude propose d'inverser le processus créatif habituel.

- ❶ **Extraction préalable** : L'algorithme commence par identifier et extraire des affirmations factuelles directement depuis le contexte.
- ❷ **Complexification** : Ces affirmations servent de base pour construire des réponses de type *summary* (en fusionnant plusieurs faits) ou des conclusions pour le *reasoning*.
- ❸ **Génération de la question** : Enfin, une question est formulée de manière à ce que l'affirmation choisie en soit la réponse unique et sans ambiguïté.

Résultat : Cette méthode garantit l'*ancrage* (grounding) des données et réduit drastiquement les hallucinations dans le dataset de test.

Stratégie 2 : Fine-Tuning de Modèles Spécialisés

L'utilisation massive de modèles géants (comme Llama-3-70b) pour la génération de données peut s'avérer coûteuse et lente.

L'approche "Small Model"

Les chercheurs ont exploré le fine-tuning de modèles plus modestes (ex : Flan-T5-large avec LoRA). L'objectif est d'enseigner spécifiquement au modèle à générer des paires Q&A diversifiées sur commande.

Résultats observés

Une fois entraîné, le petit modèle parvient à produire des jeux de données riches et équilibrés lorsqu'il est sollicité avec des étiquettes spécifiques (non-fact_single). Cela offre une solution scalable pour générer des benchmarks locaux de haute qualité.

Inférences pour notre Projet (Phase 1)

L'analyse de "Know Your RAG" nous permet de justifier les choix méthodologiques pour la suite de notre projet sur le corpus industriel.

- **Preuve par l'homogénéité** : Le chiffre de 95% de questions `fact_single` prouve que la génération synthétique "naïve" est insuffisante pour nos besoins. Elle ne permettrait pas de valider la robustesse de notre système final.
- **Nécessité du contrôle** : La taxonomie (`fact_single`, `summary`, `reasoning`) doit devenir la pierre angulaire de notre pipeline de génération. Nous devons imposer ces étiquettes pour garantir la diversité du dataset.
- **Choix de la méthode** : Nous devons adopter une stratégie ancrée (type *Statement Extraction*) ou un fine-tuning ciblé pour assurer que les questions complexes (raisonnement) soient correctement représentées et fidèles aux documents techniques.

1. Typologie : Vers une approche combinatoire

Pour éviter le biais du "95% fact_single" et s'adapter au corpus industriel (EDF/Thèses), nous devons combiner trois taxonomies :

Nature de la Réponse

(Source : *Know Your RAG*)

- **Fact_single**
- **Summary** (Synthèse)
- **Reasoning** (Inférence)
- **Unanswerable**

Complexité Cognitive

(Source : *Bloom / Graesser*)

- C1-C2 : Rappel & Compréhension
- C4-C5 : Analyse & Évaluation
- **Types** : Causalité, Interprétation, Jugement.

Diversité Structurale

(Source : *DataMorgana*)

- **Style** : Mots-clés vs Langage naturel.
- **Terminologie** : Proche du doc vs Distante.
- **Profil** : Novice vs Expert.

2. Méthodes de Génération Recommandées

L'approche "Vanilla Prompting" étant insuffisante, la Phase 2 s'appuiera sur des méthodes de contrôle accru :

Stratégie Principale : Extraction d'Affirmations (Answer-First)

- **Principe** : Extraire d'abord les affirmations du document industriel, puis générer la question.
- **Objectif** : Garantir l'ancrage (*Grounding*) et réduire les hallucinations.

Génération Contrôlée (DataMorgana)

- Instancier des prompts spécifiques basés sur la matrice de typologie (Utilisateur + Type de Question).

Extension Multimodale (Futur)

- Utilisation de VLM (Vision-Language Models) pour les schémas et graphiques techniques des documents EDF.

